

Arquitetura Convolucional Leve de Elite para Reconhecimento de Padrões no Domínio de Pixels LUMA

A seleção de uma arquitetura de Rede Neuronal Convolucional (CNN) leve para processamento direto no domínio de pixels LUMA (canal Y do espaço de cores YUV) exige uma análise rigorosa das restrições de largura de banda de memória, intensidade aritmética da camada de entrada (*stem*) e capacidade de representação espacial sem o auxílio de informação cromática¹. A eliminação dos canais de cromaticidade (U e V) reduz a pegada de dados de entrada em 66%, suprimindo a necessidade de conversão de espaço de cores a partir do sensor de imagem e permitindo a leitura direta de *buffers* de memória NV12/YUV420 gerados por Processadores de Sinal de Imagem (ISP) ou decodificadores de vídeo em tempo real¹. Para operar com sucesso sobre o canal LUMA em cenários de tomada de decisão em tempo real, a rede convolucional deve extrair gradientes espaciais, texturas e bordas de alta frequência diretamente da luminância bruta, otimizando a relação entre operações de multiplicação e acumulação (MACs) e acessos à memória (MAC/Byte)⁵.

Fundamentação Técnica do Processamento Direto no Domínio LUMA

O olho humano e os sistemas de visão computacional dependem majoritariamente da variação de luminância para identificar formas, contornos e estruturas espaciais³. No formato YUV 4:2:0 habitual em arquiteturas de hardware incorporado, o canal Y (LUMA) preserva a resolução espacial total ($H \times W \times 1$), enquanto os canais de cromaticidade são subamostrados ($H/2 \times W/2 \times 2$)².

Em arquiteturas tradicionais, o fluxo de dados exige que o sensor capture os dados brutos via interface MIPI CSI-2, passando por um bloco ISP para demosaicing e conversão para o espaço RGB². Essa conversão gera uma sobrecarga substancial de transferência de dados e consumo energético na memória DRAM². Ao reconfigurar a entrada do pipeline para operar

exclusivamente sobre o plano de luminância Y , o sistema acede diretamente ao *buffer* de memória NV12 alocado na DRAM². Esta ingestão direta elimina ciclos de processamento de CPU ou GPU associados à transformação de cor e melhora a eficiência do *cache* L1/L2, uma vez que os pixels de luminância estão armazenados de forma estritamente sequencial na memória¹.

A transição de uma entrada tridimensional RGB ($H \times W \times 3$) para uma entrada monocromática LUMA ($H \times W \times 1$) altera a intensidade aritmética da camada convolucional inicial (*stem*). Em modelos convencionais, a primeira camada aplica filtros 3×3 sobre três canais, exigindo $C_{out} \times 3 \times K^2$ parâmetros. No domínio LUMA, a carga computacional do *stem* cai para um terço ($C_{out} \times 1 \times K^2$). Embora isto reduza o custo operacional imediato, cria um desafio microarquitetural: a intensidade aritmética inicial decresce, aproximando a camada de entrada do limite de largura de banda de memória (*memory-bound*)⁵. Para contrariar este efeito e evitar estrangulamentos na transferência de ativações, a microarquitetura das camadas subsequentes deve aumentar rapidamente o número de canais internos e a densidade de cálculo sem introduzir fragmentação de operadores⁵.

Avaliação Sistemática e Comparativa das Arquiteturas CNN Leves

A avaliação do desempenho de modelos leves em cenários de recursos restritos requer a análise simultânea da precisão, da contagem de parâmetros, das operações por ponto flutuante (FLOPs) ou MACs, da latência real no hardware e do custo de acesso à memória (MAC - *Memory Access Cost*)⁵.

Arquitetura	Parâmetros (M)	FLOPs / MACs (G)	Latência Típica no Edge (ms)	Precisão Top-1 (ImageNet / CIFAR)	Compatibilidade de Hardware	Adequação ao Domínio LUMA
MobileNetV4 (MNv4-Conv-Small)	3.8	0.20	2.40 (Pixel CPU) / 0.82 (NPU)	73.8% (ImageNet)	Universal (CPU, GPU, DSP, NPU) ⁵	Excelente (Blocos UIB otimizam gradientes espaciais) ⁵
MobileNetV4 (MNv4-H)	32.6	3.60	3.80 (EdgeTPU)	87.0% (ImageNet)	Elevada (CPU, NPU) ⁵	Alta (Excelente para

ybrid-Large)						decisões complexas multiclasses) ¹²
MobileOne-S1	4.8	0.85	0.89 (iPhone 12 FP16)	75.9% (ImageNet)	Extrema (CPU, GPU mobile) ⁹	Excelente (Sem ramificações na inferência ; processamento linear de pixels) ⁹
EfficientNetV2-S	21.5	2.80	12.30 (Mobile CPU)	86.98% (CIFAR-100) / 97.57% (CIFAR-10)	Média (Limitada por acessos à memória) ¹⁴	Moderada (Custo de memória e tamanho do modelo são elevados) ¹⁵
EfficientNet-B0	5.3	0.39	3.10 (Edge GPU)	82.75% (CIFAR-100)	Alta (GPU, NPU) ¹⁰	Boa (Excelente trade-off precisão/parâmetros, mas com latência superior a MobileOne) ¹⁰

ShuffleNetV2 x1.0	2.27	0.14	1.80 (ARM CPU)	69.36% (ImageNet) / 95.83% (CIFAR-10)	Alta (CPU, DSP) ¹⁵	Boa (Muito eficiente em memória, mas menor capacidade de abstração complexa) ¹⁵
GhostNetV2	3.9	0.27	2.10 (Mobile GPU)	75.3% (ImageNet)	Alta (CPU, NPU) ¹⁷	Boa (Geração eficiente de mapas de características via operações lineares) ¹⁸
ResNet18	11.7	1.80	0.039 (Batch lat. reduzida)	76.6% (Avg Top-1) / 96.05% (CIFAR-10)	Universal (Estruturada densa) ¹⁰	Sub-ótima (Ineficiente em parâmetros e FLOPs comparada com redes fatoradas) ¹⁰
SqueezeNet	1.2	0.86	1.52 (ARM CPU)	84.48% (CIFAR-10)	Universal (Fire Modules)	Baixa (Baixa capacidade)

					10	de de extração em padrões de fina granulari dade) ¹⁵
--	--	--	--	--	----	---

Análise Microarquitetural das Soluções de Alto Desempenho

MobileNetV4 e o Universal Inverted Bottleneck (UIB)

A arquitetura MobileNetV4 destaca-se como a solução mais robusta e universalmente otimizada para ecologicamente cobrir múltiplos alvos de hardware⁵. O núcleo do MobileNetV4 assenta no bloco *Universal Inverted Bottleneck* (UIB), uma estrutura flexível que unifica o *Inverted Bottleneck* (IB) tradicional, a convolução estilo ConvNeXt, as redes *Feed-Forward* (FFN) e uma variação com Convolução Profunda Adicional (*Extra Depthwise* - ExtraDW)⁵.

A microarquitetura do bloco UIB recebe um tensor de entrada X e executa sequencialmente uma expansão de canais através de uma convolução pointwise 1×1 , seguida por até duas etapas opcionais de convolução profunda espacial (3×3 ou 5×5), finalizando com uma projecção 1×1 que reduz a dimensionalidade dos canais para corresponder à ligação

residual⁸. A flexibilidade do UIB é gerida por dois parâmetros booleanos (b_1, b_2) que ativam ou desativam as convoluções profundas antes e depois da expansão de canais, permitindo que a pesquisa de arquitetura neural (NAS) adapte a topologia do bloco às características do fluxo de dados⁸.

A transformação matemática de um bloco UIB genérico é representada formalmente por:

$$Y = \text{Proj}_{1 \times 1} \left(\text{DW}_{K_2}^{b_2} \left(\text{DW}_{K_1}^{b_1} (\text{Exp}_{1 \times 1}(X)) \right) \right) + \mathcal{F}_{\text{res}}(X)$$

onde $\text{Exp}_{1 \times 1}$ denota a expansão de canais pointwise, $\text{DW}_{K_1}^{b_1}$ e $\text{DW}_{K_2}^{b_2}$ representam as convoluções profundas espaciais ativadas condicionalmente por $b_1, b_2 \in \{\text{True}, \text{False}\}$ com kernels $K_1, K_2 \in \{3, 5\}$, e $\text{Proj}_{1 \times 1}$ realiza a projecção de regresso ao espaço de características original⁸.

Para o domínio LUMA, a inclusão do bloco ExtraDW revela-se vantajosa⁸. Uma vez que a entrada não possui variação cromática, a extração de padrões baseia-se fortemente na

apreensão de gradientes e variações de textura contíguas¹. A introdução de duas convoluções profundas consecutivas amplia o campo recetivo efetivo logo nos primeiros estágios da rede sem aumentar de forma substancial a pegada de memória ou quebrar a fusão de operadores no acelerador⁵.

MobileOne e a Reparametrização Estrutural em Tempo de Inferência

A arquitetura MobileOne resolve o gargalo de latência e de largura de banda provocado pela fragmentação de operadores e pela leitura dispersa na memória DRAM⁹. Durante a fase de treino, o modelo utiliza um bloco multi-ramificado super-parametrizado composto por convoluções 3×3 , convoluções 1×1 e ligações de identidade paralela com o objetivo de otimizar a convergência da superfície de perda⁹.

No momento do pré-processamento para implantação (*deployment*), os parâmetros das ramificações paralelas de convolução e dos módulos de normalização por lote (*Batch Normalization*) são fundidos linearmente num único núcleo convolucional equivalente de 3×3 ¹³. A transformação matemática de fusão dos pesos $W \in \mathbb{R}^{C_{out} \times C_{in} \times K \times K}$ e

parâmetros de $BN(\mu, \sigma, \gamma, \beta)$ é expressa por:

$$W'_{fused} = \frac{\gamma}{\sqrt{\sigma^2 + \epsilon}} \cdot W$$

$$b'_{fused} = \beta - \frac{\gamma \cdot \mu}{\sqrt{\sigma^2 + \epsilon}}$$

Como a adição de kernels convolucionais de dimensões equivalentes é distributiva em relação à operação de convolução, os múltiplos ramos são somados para formar o kernel final unificado:

$$W_{final} = W'_{3 \times 3} + \text{Pad}_{3 \times 3}(W'_{1 \times 1}) + \text{Pad}_{3 \times 3}(W'_{identity})$$

Esta reparametrização resulta numa topologia estritamente sequencial (*single-path*) na inferência²⁰. Para o processamento do canal LUMA, isto elimina totalmente a sobrecarga de concatenar tensores na memória e garante uma leitura contínua dos *buffers* de luminância em pipeline direto de registos, viabilizando latências sub-milissegundo em processadores móveis e microcontroladores⁹.

EfficientNet / EfficientNetV2 e os Limites do Escalonamento Composto

O EfficientNet baseia-se no escalonamento composto da profundidade (d), largura (w) e

resolução (r) da rede através de um coeficiente uniforme¹¹. Embora o EfficientNet-B0 e o EfficientNetV2-S alcancem índices de precisão superiores em conjuntos de dados gerais como CIFAR-100 e ImageNet (alcançando 82.75% e 86.98% de precisão Top-1, respectivamente)¹⁰, a sua eficiência em sistemas incorporados de decisão sofre restrições severas.

A presença de módulos *Squeeze-and-Excitation* (SE) e as ramificações MBConv elevam a taxa de leitura e escrita de ativações na DRAM, gerando latências de inferência desproporcionais às suas contagens teóricas de FLOPs⁹. Adicionalmente, o EfficientNetV2-S requer até

79.80 MB de armazenamento em formato FP32¹⁵, o que se mostra desvantajoso para microcontroladores e aceleradores NPU de baixo consumo onde o espaço SRAM/Flash é limitado a escassos megabytes¹⁶.

Eficiência Operacional e Tomada de Decisão em Tempo Real

A aplicação direta no domínio de pixels LUMA para tomada de decisão em tempo real em navegação autónoma, inspeção industrial de alta velocidade ou robótica exige que o pipeline minimize a latência total do sistema². A latência total é descrita pela soma analítica de suas componentes temporais:

$$T_{\text{total}} = T_{\text{aquisição}} + T_{\text{pré-processamento}} + T_{\text{inferência}} + T_{\text{decisão}}$$

Ao eliminar os canais de cor, a componente $T_{\text{pré-processamento}}$ desce drasticamente, uma vez que a transformação do espaço de cores e a reordenação de canais são totalmente omitidas². Num pipeline RGB tradicional, o sistema consome entre 15 ms e 35 ms apenas na conversão de formato e na transferência de tensores de três canais para a GPU/NPU². No pipeline LUMA otimizado, o *buffer* de luminância é transferido diretamente para a rede convolucional, reduzindo a fase de pré-processamento e inferência combinadas para um intervalo entre 1 ms e 4 ms².

Sem informação de cor, a capacidade de extração da rede foca-se inteiramente na análise estrutural de gradientes e texturas³. A análise de bordas e descontinuidades de intensidade manifesta-se através do gradiente espacial local de luminância:

$$\nabla I(x, y) = \left(\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y} \right)$$

As arquiteturas convolucionais leves devem possuir núcleos espaciais (3×3 ou 5×5) capazes de capturar estes gradientes logo nos primeiros estágios da rede⁸. Padrões visuais

complexos sem variação cromática — tais como microfissuras no pavimento, defeitos de superfície em tecidos ou silhuetas sob iluminação infravermelha — manifestam-se como variações de frequência espacial¹⁸. O uso de módulos como o *ExtraDW* do MobileNetV4 permite preservar o detalhe destas texturas através da expansão do campo recetivo efetivo sem compressão espacial prematura⁸.

Recomendações Técnicas e Conclusão

A escolha da arquitetura leve de CNN mais capaz para operar sobre o domínio de pixels LUMA depende do equilíbrio entre a complexidade do problema de decisão e as restrições rígidas do hardware de destino.

A recomendação principal para sistemas heterogêneos que exigem alto desempenho de classificação e capacidade de generalização é o **MobileNetV4 (MNv4-Conv-Small)**⁵. A inclusão do bloco Universal Inverted Bottleneck (UIB) configurado com *ExtraDW* maximiza a

extração de gradientes e texturas no canal Y , garantindo otimização no modelo Roofline e Pareto-optimalidade cruzada entre CPUs, GPUs, DSPs e NPU⁵. Para cenários de complexidade multiclasse muito elevada, a variação **MNv4-Hybrid-Large** oferece uma precisão de nível de estado da arte (87.0% Top-1 no ImageNet) com um tempo de execução de apenas 3.8 ms no EdgeTPU⁵.

Para aplicações de latência crítica sub-milissegundo em processadores móveis ou unidades de cálculo de baixa gama, a arquitetura recomendada é o **MobileOne-S1**⁹. A sua técnica de reparametrização estrutural converte o modelo num caminho único e sequencial durante a inferência, eliminando custos de concatenação de memória e permitindo a ingestão

ultra-rápida de linhas de pixels LUMA a taxas superiores a 1000 FPS¹³.

A substituição de pipelines de visão tradicionais baseados em RGB por modelos convolucionais leves dedicados ao processamento do canal LUMA reduz o consumo energético global do sistema e garante tomadas de decisão rápidas e precisas no Edge².

Referências citadas

1. US20240305785A1 - Efficient warping-based neural video codec - Google Patents, <https://patents.google.com/patent/US20240305785A1/en>
2. ai-hardware-engineer-roadmap/Phase 3 - Artificial Intelligence/Track A - Hardware and Edge AI/3. Computer Vision/Guide.md at main - GitHub, <https://github.com/ai-hpc/ai-hardware-engineer-roadmap/blob/main/Phase%203%20-%20Artificial%20Intelligence/Track%20A%20-%20Hardware%20and%20Edge%20AI/3.%20Computer%20Vision/Guide.md>
3. Color Models in Image Processing: A Review and Experimental Comparison Corresponding author - arXiv, <https://arxiv.org/html/2510.00584v1>
4. YUV-based Deep Learning Super-Resolution for Bitrate Reduction and ROI Preservation in Modern Video Codecs - ResearchGate, https://www.researchgate.net/publication/403424963_YUV-based_Deep_Learning

[_Super-Resolution_for_Bitrate_Reduction_and_ROI_Preservation_in_Modern_Video_Codecs](#)

5. MobileNetV4 - Universal Models for the Mobile Ecosystem - arXiv, <https://arxiv.org/html/2404.10518v1>
6. From MobileNet to RepViT: A Survey of Edge-Optimized Computer Vision Architectures - ScholarWorks@UARK, <https://scholarworks.uark.edu/cgi/viewcontent.cgi?article=1042&context=elcsuht>
7. AIM 2022 Challenge on Super-Resolution of Compressed Image and Video: Dataset, Methods and Results - Milano-Bicocca, <https://boa.unimib.it/bitstream/10281/415436/1/Yang-2023-Lect%20Notes%20Computer%20Sci-preprint%20.pdf>
8. Universal Inverted Bottleneck (UIB) - Emergent Mind, <https://www.emergentmind.com/topics/universal-inverted-bottleneck-uib>
9. Apple's MobileOne Backbone Reduces Inference Time to Under One Millisecond on an iPhone12 and Reaches 75.9% Top-1 Accuracy on ImageNet | Synced, <https://syncedreview.com/2022/06/15/apples-mobileone-backbone-reduces-inference-time-to-under-one-millisecond-on-an-iphone12-and-reaches-75-9-top-1-accuracy-on-imagenet/>
10. Rethinking Efficiency: A Comparative Study of Lightweight CNN Architectures for Image Classification | Scilit, <https://www.scilit.com/publications/e04996fda4109c08477ce1b18de4b65a>
11. A Reproducible Benchmark of Lightweight CNNs: Accuracy, Efficiency, and the Impact of Pretrained Initialization - arXiv, <https://arxiv.org/html/2505.03303v3>
12. [PDF] MobileNetV4 - Universal Models for the Mobile Ecosystem - Semantic Scholar, <https://www.semanticscholar.org/paper/MobileNetV4-Universal-Models-for-the-Mobile-Qin-Leichner/3891db6b0adc2de204d89dceced1a739674340d6>
13. MobileOne: An Improved One millisecond Mobile Backbone - Semantic Scholar, <https://www.semanticscholar.org/paper/MobileOne%3A-An-Improved-One-millisecond-Mobile-Vasu-Gabriel/d83105503f3b7c6403e812cc1d354b270ab4c048>
14. [2505.03303] Comparative Analysis of Lightweight CNNs for Resource-Constrained Devices: Predictive Performance, Efficiency Trade-offs, and Initialization Effects - arXiv, <https://arxiv.org/abs/2505.03303>
15. Comparative Analysis of Lightweight Deep Learning Models for Memory-Constrained Devices - arXiv, <https://arxiv.org/html/2505.03303v2>
16. Designing Lightweight CNN for Images: Architectural Components and Techniques - River Publishers, https://www.riverpublishers.com/downloadchapter.php?file=RP_9788770041010C5.pdf
17. Beyond ImageNet: Understanding Cross-Dataset Robustness of Lightweight Vision Models, <https://arxiv.org/html/2511.00335v1>
18. A Lightweight CNN Model Based on GhostNet - ResearchGate, https://www.researchgate.net/publication/362392711_A_Lightweight_CNN_Model_Based_on_GhostNet
19. A Lightweight End-to-End Framework for Real-Time Vehicle-Ejected Debris

- Detection on Edge Devices - MDPI, <https://www.mdpi.com/1424-8220/26/14/4386>
20. MobileOne: An Improved One millisecond Mobile Backbone | Request PDF - ResearchGate, https://www.researchgate.net/publication/373327572_MobileOne_An_Improved_One_millisecond_Mobile_Backbone
 21. Experimental Comparison of Light-Weight and Deep CNN Models Across Diverse Datasets, <https://arxiv.org/html/2601.03463v1>
 22. PSRGAN-RK: Real-time infrared super-resolution based on MobileNetV4 and RKNN - AIP Publishing, <https://pubs.aip.org/aip/adv/article/16/1/015033/3378138/PSRGAN-RK-Real-time-infrared-super-resolution>
 23. MobileNetV4: Universal Models for the Mobile Ecosystem | Request PDF - ResearchGate, https://www.researchgate.net/publication/385696003_MobileNetV4_Universal_Models_for_the_Mobile_Ecosystem